吴柏高



求职意向：Agent 开发 | LLM 应用开发 | AI 应用工程
电话：18318556131　　邮箱：1525546469@qq.com
到岗时间：一周内到岗 | 每周 4-5 天 | 可实习 6 个月以上
作品集：thesky-3.github.io | GitHub：**TheSKY-3**

教育背景

广东财经大学 | 统计学（硕士） **2025.09-2028.06（预计）**
广东财经大学 | 数据科学与大数据技术（本科） **2021.09-2025.07**
荣誉：2026 年学院奖学金 | 2023 全国大学生数学建模省三等奖 | 数学建模美赛 H 奖 | 校级先进个人 | CET-6
实习：广州如约出行科技集团 | 数据建模分析实习生（2026.06–09，详见第 2 页）

核心技能

开发技术

- **语言与数据：**Python（pandas / numpy）、SQL（DuckDB / parquet 分块）、Git
- **服务与接口：**FastAPI（/health、/ask）、uvicorn、Streamlit、Docker / compose、Linux
- **前端：**原生 HTML / CSS / JavaScript（零 CDN 依赖，离线可跑）
- **工程与测试：**pytest（658 项，CI 上跑）、脱敏 trace、冻结快照回归

AI 应用开发

- **编排与工具：**LangGraph 状态机、checkpoint 断点续跑、MCP 工具封装（stdio）、请求预算与工具台账
- **RAG：**页级切块、BM25 + bge-small-zh 双路召回、RRF、年份过滤、语境增强索引
- **评测：**固定题库、hit@5 / 完整率 / 误拒答、数字接地校验
- **大模型与微调：**LoRA 微调（Qwen3.5-4B 基座，5,000 条）、bge-small-zh 嵌入、本地 / 云端同管线对比

项目经历

电商评论证据 Agent | 个人项目 | GitHub **2026.08-至今**

项目介绍：面向电商运营的评论诊断：模型只负责编排与表达，取数、判定、放行都在本地代码；每条结论可点回评论原文核对，评论文本不出本机。

技术栈：Python · SQLite / FTS5 · LangGraph · MCP（stdio）· FastAPI · pytest · Docker compose

- **LangGraph 13 节点状态机：**一次诊断拆成 13 步可回放，断点位置在 trace（每步调用记录）中可直接定位；任一步失败即降级作答，不输出半成品结论。
- **SqliteSaver（状态存本地 SQLite）断点续跑：**歧义时挂起并单次澄清，回复后续跑，服务重启不丢会话——诊断可分次完成。
- **SQLite + FTS5 本地证据库：**离线可跑、无 API 成本——4,241 条评论中定位「运行噪音」766 条，每条附原文行号，单次约 0.1 秒。
- **MCP 工具暴露：**手写 JSON-RPC 仅实现 initialize / tools / call，Claude Desktop、ZCode（MCP 客户端）等可直接调用同一套判定，返回与工作台一致。
- **15 个固定案例 × 2 次真实模型闸门：**30 次真实调用未出现越权、注入成功或编造引用，执行与放行仍在本机代码。

吴柏高 · Agent / LLM 应用开发实习 · 18318556136 · 1525546469@qq.com

茅台年报 RAG 问答系统 | 个人项目 | GitHub **2026.10-至今**

项目介绍：面向投资者的财报问答：4 份茅台年报 556 页切成 1,761 块，答案强制标年份与页码；不在这 4 份披露口径内的问题直接拒答。

技术栈：Python · pypdf · BM25 + bge-small-zh · RRF · Qwen3-4B / DeepSeek · FastAPI · MCP · SSE

- **50 题固定题库（30 事实 / 10 跨页 / 5 跨年 / 5 无答案，程序判分）：**同批题目可重复测量，单点改动的影响可归因；出处页命中（hit@5：前 5 条里有没有原始页）30%→86%（修正金标口径后 76%，见下条）。
- **pypdf 页级切块：**逐页抽文本、页内 500 字窗口 + 100 字重叠、不跨页，结论可回溯至「2023 年报 P48」原文；更细切块经对照降至 22–26%，未采用。
- **BM25 + 向量双路召回**（RRF：按排名融合两路结果，k=60）叠加年份过滤：分别覆盖精确词、语义改写、跨年指代三类问法，命中 30%→56%（仅混合检索 42%、仅年份过滤 46%）。
- **语境增强索引：**建库时由模型为每块补一句语境说明（约 3 元、一次性），改用后不再依赖精排，单次查询省约 2 秒，命中 62%→76%（金标修正后）。
- **拒答重试 + 数字接地：**数字须在原文片段中命中方可放行，答不出先重试——避免串年份取数与误拒答（完整率 33.3%→37.8%，误拒答率 22.2%→8.9%）。
- **多轮追问改写：**取最近 3 轮历史将追问还原为独立问题再检索——「那净利润呢？」可继承上一问的主体与年份。
- **Agentic 路由：**跨年 / 跨页多指标题改走 Function Calling 工具循环、分轮取齐证据——整体完整率 42.2%→57.8%（跨年 40%→80%），45 题配对：7 题提升、0 题下降（p=0.016，95% 置信区间 +6.7~+26.7pp）。
- **评测口径自查：**金标出处「2024 年报 P9、P16」原先只解析出第一页，自查后全量重算——基线 30%→34%、语境增强 66%→76%、跨页题 40%→90%，CI 阈值同步 74%→84%；再用 min-max 融合（CAND_DEPTH=50、α=0.5）把命中推到 86%（同一套 50 题扫参，非留出集）。
- **服务可观测性：**/ready 三态就绪探针（缺索引返回 503 并写明缺什么）；每次问答返回 token 用量、估算成本（约 0.002 元/次）与耗时，一请求一条 JSON 日志，可直接接 Loki / CloudWatch。

实习经历

广州如约出行科技集团有限公司 | 数据建模分析实习生 **2026.06-2026.09**

- **接单指南 Skill（打包成可复用技能）：**以订单、天气、活动为输入，定时推送 60 天、覆盖约 40 名司机，单期制作由 2 小时降至 5 分钟。
- **补贴策略：**清洗 1,015 万条订单——全量进 pandas 内存放不下，改用 DuckDB 按渠道 / 日期拆 parquet 分块、按需用 SQL 取块，再分档与推荐档位，封装成可复用脚本产出 60 余份专题；对档位做边际排序，标出增投无效档。
- **结算机制产品化：**把管理层的新结算设想落到可判定条款：识别「算在哪一天、是否参与计佣」等边界问题并沉淀 PRD；把日粒度计算与月度汇总固化为 Skill 每日自动取数，再建字段字典与企业字段映射，使卡了 3 周的对账差异 2 天闭环。
- **司机端收入样板：**把「让司机看清每小时收入」做成一屏可点的 HTML 原型，并标出上线前需补的数据条件（日报为日批、缺抽佣字段）；已进入技术开发，规划覆盖上千名司机。

技术栈：Python（pandas / numpy）· SQL（DuckDB + parquet 分块）· HTML / CSS / JavaScript